



BIG DATA & DATA MINING

Lecturer : Kusnawi,S.Kom, M.Eng
Email : Khusnawi@amikom.ac.id
Instagram: @mynameiskhus

✓ BIG DATA & DATA MINING - WEEK 3

Objektif :

Mahasiswa dapat menerapkan teknik dasar preprocessing data

Preprocessing data

Langkah awal dalam analisis data yang melibatkan pembersihan, transformasi, dan persiapan data mentah agar sesuai untuk analisis lebih lanjut. Ini melibatkan penghapusan nilai yang hilang, normalisasi skala, serta konversi atau ekstraksi fitur yang relevan guna meningkatkan kualitas dan kemudahan pemrosesan data. Tujuannya adalah untuk memastikan data siap digunakan oleh model atau algoritma tanpa menyebabkan distorsi atau kehilangan informasi yang signifikan.

```
#Kita Gunakan dataset titanic dan tersedia di platform kaggle
import pandas as pd
df = pd.read_csv('/content/titanic.csv')
df.head()
```

[Show hidden output](#)

Next steps:

[Generate code with df](#)

[New interactive sheet](#)

```
# info() digunakan untuk menampilkan informasi detail tentang dataframe,
#seperti jumlah baris data, nama-nama kolom berserta jumlah data dan tipe datanya, dan sebagainya.
df.info()
```

[Show hidden output](#)

```
#Check Duplication
#Digunakan untuk menghitung jumlah nilai unik di setiap kolom dalam DataFrame
df.nunique()
```

```
0
PassengerId  891
Survived     2
Pclass       3
Name         891
Sex          2
Age         88
SibSp        7
Parch        7
Ticket      681
Fare        248
Cabin       147
Embarked     3
```

dtype: int64

```
df["Sex"].unique()
df["Age"].unique()
```

```
array(['male', 'female'], dtype=object)
```

```
#describe() digunakan untuk menampilkan deskriptif statistik data.
#Hanya kolom yang bertipe numerik yang akan ditampilkan statistiknya.
df.describe()
```

	PassengerId	Survived	Pclass	Age	SibSp	Parch	Fare	
count	891.000000	891.000000	891.000000	714.000000	891.000000	891.000000	891.000000	
mean	446.000000	0.383838	2.308642	29.699118	0.523008	0.381594	32.204208	
std	257.353842	0.486592	0.836071	14.526497	1.102743	0.806057	49.693429	
min	1.000000	0.000000	1.000000	0.420000	0.000000	0.000000	0.000000	
25%	223.500000	0.000000	2.000000	20.125000	0.000000	0.000000	7.910400	
50%	446.000000	0.000000	3.000000	28.000000	0.000000	0.000000	14.454200	
75%	668.500000	1.000000	3.000000	38.000000	1.000000	0.000000	31.000000	
max	891.000000	1.000000	3.000000	80.000000	8.000000	6.000000	512.329200	

Penjelasan :

- count: Jumlah baris non-null dalam kolom.
- mean: Nilai rata-rata dari kolom.
- std: Standar deviasi, ukuran seberapa tersebar nilai-nilai dalam kolom.
- min: Nilai minimum dalam kolom.
- 25%: Kuartil pertama (persentil ke-25), nilai di mana 25% data lebih kecil dari nilai ini.
- 50%: Median (persentil ke-50), nilai tengah dari data yang diurutkan.
- 75%: Kuartil ketiga (persentil ke-75), nilai di mana 75% data lebih kecil dari nilai ini.
- max: Nilai maksimum dalam kolom.

Misal pada Age.

- Terdapat 714 baris non-null.
- Usia rata-rata adalah sekitar 29.7 tahun.
- Standar deviasi usia adalah sekitar 14.5 tahun.
- Usia termuda adalah 0.42 tahun.
- 25% penumpang berusia di bawah 20.125 tahun.
- Median usia adalah 28 tahun.
- 75% penumpang berusia di bawah 38 tahun.
- Usia tertua adalah 80 tahun.

```
#mencari jumlah baris data yang bernilai null
#terdapat kolom age , cabin, dan embarked memiliki nilai kosong
df.isnull().sum()
```

	0
PassengerId	0
Survived	0
Pclass	0
Name	0
Sex	0
Age	177
SibSp	0
Parch	0
Ticket	0
Fare	0
Cabin	687
Embarked	2

dtype: int64

```
#menampilkan data yang null
data=df["Embarked"].isnull()
df[data]
```

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	
61	62	1	1	Icard, Miss. Amelie	female	38.0	0	0	113572	80.0	B28	NaN	
829	830	1	1	Stone, Mrs. George	female	62.0	0	0	113572	80.0	B28	NaN	

kolom Embarked, Jika kita mau abaikan dengan alasan tertentu, maka kita hapus saja baris dengan nilai null pada `df = df.dropna(subset=['Embarked'])`

#cek dataframe hasil menghapus
`df.isnull().sum()`

	0
PassengerId	0
Survived	0
Pclass	0
Name	0
Sex	0
Age	177
SibSp	0
Parch	0
Ticket	0
Fare	0
Cabin	687
Embarked	0

`dtype: int64`

`data=df["Age"].isnull()`
`df[data]`

PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	
5	6	0	3	Moran, Mr. James	male	NaN	0	0	330877	8.4583	NaN	Q
17	18	1	2	Williams, Mr. Charles Eugene	male	NaN	0	0	244373	13.0000	NaN	S
19	20	1	3	Masselmani, Mrs. Fatima	female	NaN	0	0	2649	7.2250	NaN	C
26	27	0	3	Emir, Mr. Farred Chehab	male	NaN	0	0	2631	7.2250	NaN	C
28	29	1	3	O'Dwyer, Miss. Ellen "Nellie"	female	NaN	0	0	330959	7.8792	NaN	Q
...	...	...	...	...	...	...	...	...	...	...	...	...
859	860	0	3	Razi, Mr. Raihed	male	NaN	0	0	2629	7.2292	NaN	C
863	864	0	3	Sage, Miss. Dorothy Edith "Dolly"	female	NaN	8	2	CA. 2343	69.5500	NaN	S
868	869	0	3	van Melkebeke, Mr. Philemon	male	NaN	0	0	345777	9.5000	NaN	S

#Jika menemukan data null yang dominan dan jika dihapus akan mempengaruhi hasil analisis, maka bisa melakukan beberapa langkah
#Contoh pada kolom Age, kita isikan dengan nilai rata-rata dari data yang lain

Langkah 1
`rata_umur = df['Age'].mean()`
Langkah 2 , disisi hasil dari langkah 1
`df['Age'] = df['Age'].fillna(rata_umur)`
Langkah 3
`df['Age'].isna().sum()`

`np.int64(0)`

`df.isnull().sum()`

```
      0
PassengerId  0
Survived     0
Pclass      0
Name        0
Sex         0
Age         0
SibSp       0
Parch       0
Ticket      0
Fare        0
Cabin      687
Embarked    0
```

dtype: int64

```
#Menampilkan hasil isi data Age
df["Age"]
```

```
      Age
0  22.000000
1  38.000000
2  26.000000
3  35.000000
4  35.000000
...     ...
886  27.000000
887  19.000000
888  29.642093
889  26.000000
890  32.000000
```

889 rows x 1 columns

dtype: float64

```
# Pada Cabin juga ditemukan nilai null dan proses pengisian data null dengan modus (sesuai kebutuhan dan arah hasil)
# Modus adalah nilai yang paling sering muncul dalam suatu data statistika.
# Modus juga merupakan nilai mayoritas atau nilai dengan frekuensi paling tinggi.
# Langkah 1
modus = df['Cabin'].mode()[0]
print (modus)
```

B96 B98

```
# Langkah 2 dengan fungsi fillna memasukkan nilai tetap
df['Cabin'] = df['Cabin'].fillna(modus)
# Langkah 3 untuk mengecek data
df['Cabin'].isna().sum()
```

np.int64(0)

```
#Menampilkan hasil isi data Cabin
df["Cabin"]
```

Cabin

```
0    B96 B98
1         C85
2    B96 B98
3         C123
4    B96 B98
...
886   B96 B98
887         B42
888   B96 B98
889         C148
890   B96 B98
```

889 rows × 1 columns

dtype: object

```
#memastikan dataset tidak ada yang bernilai Null
df.isnull().sum()
```

```
0
PassengerId  0
Survived     0
Pclass       0
Name         0
Sex          0
Age          0
SibSp        0
Parch        0
Ticket       0
Fare         0
Cabin        0
Embarked     0
```

dtype: int64

```
#menggunakan method duplicated
df.sort_values("Cabin", inplace=True)
df["Cabin"]
```

```
Cabin
583    A10
475    A14
556    A16
284    A19
599    A20
...
10     G6
205    G6
251    G6
394    G6
339     T
```

889 rows × 1 columns

dtype: object

df.Cabin.duplicated() # mengecek hasil duplikasi

Cabin	
583	False
475	False
556	False
284	False
599	False
...	...
10	False
205	True
251	True
394	True
339	False

889 rows x 1 columns

dtype: bool

df.Cabin.duplicated().sum() #Jumlah

np.int64(743)

(~df.Cabin.duplicated()).sum() # jumlah yang tidak duplikat

np.int64(146)

#catatan df.loc[], cara standar untuk mengakses sekelompok baris dan kolom berdasarkan label
df.loc[df.duplicated(), :] # Mengidentifikasi baris yang duplikat
df.head()

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	
583	584	0	1	Ross, Mr. John Hugo	male	36.000000	0	0	13049	40.1250	A10	C	
475	476	0	1	Clifford, Mr. George Quincy	male	29.642093	0	0	110465	52.0000	A14	S	
556	557	1	1	Duff Gordon, Lady. (Lucille Christiana	female	48.000000	1	0	11755	39.6000	A16	C	

Next steps:

[Generate code with df](#)

[New interactive sheet](#)

df.loc[df.duplicated(keep=False), :] # menghasilkan Series Boolean yang menunjukkan baris mana yang merupakan dupl:
df.tail()

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	
10	11	1	3	Sandstrom, Miss. Marguerite Rut	female	4.0	1	1	PP 9549	16.7000	G6	S	
205	206	0	3	Strom, Miss. Telma Matilda	female	2.0	0	1	347054	10.4625	G6	S	
251	252	0	3	Strom, Mrs. Wilhelm (Elna Matilda Persson)	female	29.0	1	1	347054	10.4625	G6	S	

#drop semua duplicates
df.drop_duplicates(keep=False)
df.duplicated()

```

0
583 False
475 False
556 False
284 False
599 False
...
10 False


```

```

205 False
267 False
394 False

```

✓ Data Pecilan atau Outlier



Outlier adalah nilai ekstrim bisa memengaruhi hasil analisis secara signifikan

✓ PENUGASAN

A. Tema Pecilaan dan Visualisasi Data

1. Berikan contoh dataset yang terdapat data pencilan atau diambil dari dataset pada penugasan praktikum week 1 dan Visualisasikan dataset tersebut menggunakan scatterplot dan boxplot
2. Abaikan/Buang data pencilan tersebut
3. Visualisasikan lagi setelah data pencilan dibuang dan amati perbedaanya.
4. Berikan kesimpulan

B. Link pengumpulan : <https://forms.gle/S9gvjS2Vt2H1GwpW6>

Catatan : Sebelum Mengerjakan Penugasan Pasti semua materi modul sudah dikerjakan

Referensi :

<https://ngodingdata.com/python-pandas-cara-menangani-missing-value/>

<https://ilmudatapy.com/20-function-di-pandas-python-yang-perlu-diketahui-pemula/>

[https://id.wikihow.com/Mendeteksi-Outlier-\(Pencilan\)](https://id.wikihow.com/Mendeteksi-Outlier-(Pencilan))