



BIG DATA & DATA MINING

Lecturer : Kusnawi,S.Kom, M.Eng
Email : Khusnawi@amikom.ac.id
Instagram: @mynameiskhus

~ BIG DATA & DATA MINING - WEEK 5

Objektif :

Mahasiswa dapat menerapkan teknik feature selection

Feature selection

atau seleksi fitur adalah salah satu teknik penting dan sering digunakan dalam tahap pre-processing. Teknik ini mengurangi jumlah fitur yang terlibat dalam menentukan suatu nilai kelas target. Fitur yang diabaikan biasanya berupa fitur yang tidak relevan dan data berlebih. Tujuan utama dari seleksi fitur ialah memilih fitur terbaik dari suatu kumpulan data fitur.

Metode Feature Selection

1. Filter Method

Metode ini akan memilih fitur yang relevan tanpa bergantung pada jenis algoritma learning yang digunakan. Metode ini mengukur relevansi sebuah fitur dengan menggunakan bantuan uji statistik. Filter method cukup cepat dan ringan secara komputasi.

2. Wrapper Method

Metode wrapper adalah proses pemilihan fitur didasarkan pada algoritma learning yang digunakan. Metode ini mengikuti pendekatan greedy searching dengan mengevaluasi model terhadap semua kombinasi fitur

3. Embedded Method

Metode embedded menggabungkan kelebihan filter dan wrapper, namun tidak semua algoritma memiliki kemampuan atau fitur ini.

Double-click (or enter) to edit

~ Load Dataset

```
import pandas as pd
pd.set_option('display.max_columns', None)
df = pd.read_csv('/content/StudentPerformance-2.csv')
df.head()
```

	id_mhs	nama	jenis_kelamin	umur	jurusan	konsentrasi	asal	kos	uang_saku	paket_data	kendaraan	laptop	tip
0	1	Julianto	Pria	21	Informatika	Pemrograman	Yogyakarta	Tidak	200000	50000	Motor	Ya	
1	2	Siti Muniroh	Wanita	22	Informatika	Jaringan	Jakarta	Ya	500000	70000	Mobil	Ya	
2	3	Achmad Sandi	Pria	21	Informatika	Multimedia	Yogyakarta	Tidak	300000	100000	Motor	Ya	
3	4	Adam Sautin	Pria	20	Informatika	Jaringan	Yogyakarta	Tidak	700000	100000	Sepeda	Ya	
4	5	Ade R. S1rief	Pria	19	Informatika	Multimedia	Surabaya	Ya	800000	80000	Mobil	Ya	

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 150 entries, 0 to 149
Data columns (total 34 columns):
#   Column                                Non-Null Count  Dtype
---  ---                                -
0   id_mhs                                150 non-null    int64
1   nama                                  150 non-null    object
2   jenis_kelamin                        150 non-null    object
3   umur                                  150 non-null    int64
4   jurusan                              150 non-null    object
5   konsentrasi                           150 non-null    object
6   asal                                  150 non-null    object
7   kos                                    150 non-null    object
8   uang_saku                             150 non-null    int64
9   paket_data                            150 non-null    int64
10  kendaraan                             150 non-null    object
11  laptop                                150 non-null    object
12  tipe_laptop                           150 non-null    object
13  status_menikah                        150 non-null    object
14  ip_sem1                                150 non-null    float64
15  ip_sem2                                150 non-null    float64
16  ip_sem3                                150 non-null    float64
17  ip_sem4                                150 non-null    float64
18  persentase_presensi                   150 non-null    int64
19  kacamata                              150 non-null    object
20  gamer                                  150 non-null    object
21  durasi_sosmed (jam/hari)              150 non-null    int64
22  jumlah_akun_sosmed                   150 non-null    int64
23  clubbing                              150 non-null    object
24  jumlah_org                            150 non-null    int64
25  score_toefl                           150 non-null    int64
26  jumlah_lomba                          150 non-null    int64
27  keadaan_ortu_divorced                 150 non-null    object
28  romance                               150 non-null    object
29  ukuran_sepatu                         150 non-null    int64
30  tinggi_badan                         150 non-null    int64
31  berat_badan                           150 non-null    float64
32  ipk                                    150 non-null    float64
33  lulus_tepatwaktu                      150 non-null    object
dtypes: float64(6), int64(12), object(16)
memory usage: 40.0+ KB
```

```
#Menampilkan fitur yang non numeric
for col in df.columns:
    if df[col].dtype not in ['int64', 'float64', 'int32']:
        print(col)
```

```
nama
jenis_kelamin
jurusan
konsentrasi
asal
kos
kendaraan
laptop
tipe_laptop
status_menikah
kacamata
gamer
clubbing
keadaan_ortu_divorced
romance
lulus_tepatwaktu
```

✓ Pre-processing Data

✓ Encoding

Digunakan untuk mengubah string kategori ke dalam bentuk numerik, hasil encoding secara otomatis dilakukan berdasarkan urutan alfabet string kategori tersebut

```
from sklearn.preprocessing import LabelEncoder

#encode otomatis
# pembuatan instance labelencoder
le = LabelEncoder()
```

```
cols = ['konsentrasi', 'asal', 'kendaraan', 'tipe_laptop',
        'jenis_kelamin', 'kos', 'laptop', 'status_menikah',
        'kacamata', 'gamer', 'clubbing', 'keadaan_ortu_divorced',
        'romance', 'lulus_tepatwaktu']

for col in cols:
    df[col] = le.fit_transform(df[col])

df.head()
```

	id_mhs	nama	jenis_kelamin	umur	jurusan	konsentrasi	asal	kos	uang_saku	paket_data	kendaraan	laptop	tipe_lap
0	1	Julianto		0	21	Informatika	2	12	0	200000	50000	1	1
1	2	Siti Muniroh	1	22	Informatika	0	3	1	500000	70000	0	1	
2	3	Achmad Sandi	0	21	Informatika	1	12	0	300000	100000	1	1	
3	4	Adam Sautin	0	20	Informatika	0	12	0	700000	100000	2	1	
4	5	Ade R. Strief	0	19	Informatika	1	11	1	800000	80000	0	1	

Drop Columns

```
#drop kolom yang memiliki tipe data object
columns = ['id_mhs', 'nama', 'jurusan']
df.drop(columns, inplace=True, axis=1)
```

1. Filter Method

Pearson Correlation

Analisis korelasi adalah teknik analisis yang digunakan untuk mengukur kuat lemahnya hubungan dua variabel. Variabel ini terdiri dari variabel bebas dan tergantung. Besarnya hubungan berkisar antara 0-1. Jika mendekati angka 1 berarti hubungan kedua variabel semakin kuat, demikian juga sebaliknya jika mendekati angka 0 berarti hubungan kedua variabel semakin lemah. Dalam scikit-learn korelasi Pearson dilakukan dengan memanggil fungsi `corr()`.

```
import numpy as np
import seaborn as sns #menampilkan matrik korelasi dalam grafik heatmap dengan menggunakan library Seaborn.
import matplotlib.pyplot as plt

cor = df.corr()
plt.figure(figsize=(24,22))
sns.heatmap(cor, cmap='Blues', annot=True)
plt.show()
```

[Show hidden output](#)

```
# Correlation with output variable
cor_target = abs(cor['persentase_presensi'])

# Selecting top 10 highly correlated features
relevant_features = cor_target.sort_values(ascending=False)
print("Top 10 features with the strongest correlation to 'persentase_presensi':")
print(relevant_features.head(10))
```

```
Top 10 features with the strongest correlation to 'persentase_presensi':
persentase_presensi      1.000000
score_toefl              0.892309
durasi_sosmed (jam/hari)  0.832496
umur                    0.817690
jumlah_akun_sosmed       0.782249
jumlah_lomba             0.738859
jumlah_org               0.728082
ipk                     0.706835
```

```
lulus_tepatwaktu      0.579645
ip_sem3                0.430141
Name: persentase_presensi, dtype: float64
```

```
#Correlation with output variable
cor_target = abs(cor['persentase_presensi'])

#Selecting highly correlated features
relevant_features = cor_target[cor_target>0.6]
relevant_features
```

	persentase_presensi
umur	0.817690
persentase_presensi	1.000000
durasi_sosmed (jam/hari)	0.832496
jumlah_akun_sosmed	0.782249
jumlah_org	0.728082
score_toefl	0.892309
jumlah_lomba	0.738859
ipk	0.706835

dtype: float64

```
print(df[["umur","persentase_presensi"]].corr())
print('\n',df[["umur","jumlah_akun_sosmed"]].corr())
print('\n',df[["umur","score_toefl"]].corr())
print('\n',df[["persentase_presensi","jumlah_akun_sosmed"]].corr())
print('\n',df[["persentase_presensi","score_toefl"]].corr())
print('\n',df[["jumlah_akun_sosmed","score_toefl"]].corr())
```

	umur	persentase_presensi
umur	1.000000	-0.81769
persentase_presensi	-0.81769	1.000000

	umur	jumlah_akun_sosmed
umur	1.000000	0.724317
jumlah_akun_sosmed	0.724317	1.000000

	umur	score_toefl
umur	1.000000	-0.783581
score_toefl	-0.783581	1.000000

	persentase_presensi	jumlah_akun_sosmed
persentase_presensi	1.000000	-0.782249
jumlah_akun_sosmed	-0.782249	1.000000

	persentase_presensi	score_toefl
persentase_presensi	1.000000	0.892309
score_toefl	0.892309	1.000000

	jumlah_akun_sosmed	score_toefl
jumlah_akun_sosmed	1.000000	-0.789821
score_toefl	-0.789821	1.000000

```
display(cor)
```

[Show hidden output](#)

2. Wrapper Method

Metode wrapper membutuhkan satu jenis algoritma Machine Learning dan menggunakan kinerjanya sebagai kriteria evaluasi. Metode ini mencari fitur yang paling cocok untuk algoritma Machine Learning dan bertujuan untuk meningkatkan kinerja algoritma.

Forward Selection

Metode seleksi berulang yang dimulai dengan fitur kosong pada model. Dalam setiap iterasi atau perulangan, kita menambahkan fitur yang memiliki pengaruh paling signifikan dalam meningkatkan model yang kita miliki. Kemudian dilanjutkan dengan penambahan variabel

baru yang tidak meningkatkan kinerja model.

Langkah-langkah teknik Forward Selection adalah sebagai berikut :

1. Pilih tingkat signifikansi (misalnya SL = 0,05 dengan kepercayaan 95%).
2. Sesuaikan semua kemungkinan model regresi sederhana dengan mempertimbangkan satu fitur pada satu waktu. Model total 'n' dimungkinkan. Pilih fitur dengan nilai p terendah.
3. Sesuaikan semua model yang memungkinkan dengan satu fitur tambahan yang ditambahkan ke fitur yang dipilih sebelumnya.
4. Sekali lagi, pilih fitur dengan nilai p minimum. jika $p_value < \text{tingkat signifikansi}$ maka lanjutkan ke Langkah 3, jika tidak hentikan prose

```
import warnings
warnings.filterwarnings('ignore')
```

```
X = df.drop("persentase_presensi", axis=1) #Feature Matrix
y = df["persentase_presensi"]           #Target Variable
```

```
import statsmodels.api as sm
```

```
def forward_selection(data, target, significance_level=0.05): #Choose a significance level (e.g. SL = 0.05 with a 95% co
    initial_features = data.columns.tolist() #convert kolom ke dalam bentuk list
    best_features = []
    while (len(initial_features)>0):
        remaining_features = list(set(initial_features)-set(best_features))
        new_pval = pd.Series(index=remaining_features)
        for new_column in remaining_features:
            model = sm.OLS(target, sm.add_constant(data[best_features+[new_column]])).fit()
            new_pval[new_column] = model.pvalues[new_column]
        min_p_value = new_pval.min()
        if(min_p_value<significance_level):
            best_features.append(new_pval.idxmin())
        else:
            break
    return best_features
```

```
forward_selection(X,y)
```

```
['score_toefl',
 'durasi_sosmed (jam/hari)',
 'umur',
 'jumlah_org',
 'ipk',
 'uang_saku']
```

▼ Backward Elimination

Berkebalikan dengan metode forward selection, pada metode ini model berisi semua fitur. Kemudian pada setiap iterasi atau perulangan dilakukan penghapusan fitur yang tidak meningkatkan kinerja model secara signifikan. Kita mengulangi proses ini sampai model berisi fitur yang ideal, ditandai dengan tidak ada perubahan yang ditemukan ketika dilakukan penghapusan fitur.

```
def backward_elimination(data, target,significance_level = 0.05): #Choose a significance level (e.g. SL = 0.05 with a 95
    features = data.columns.tolist()
    while(len(features)>0):
        features_with_constant = sm.add_constant(data[features])
        p_values = sm.OLS(target, features_with_constant).fit().pvalues[1:]
        max_p_value = p_values.max()
        if(max_p_value >= significance_level):
            excluded_feature = p_values.idxmax()
            features.remove(excluded_feature)
        else:
            break
    return features
```

```
backward_elimination(X,y)
```

```
['umur',
 'status_menikah',
 'ip_sem4',
 'gamer',
 'durasi_sosmed (jam/hari)',
```


```
'jumlah_org',  
'score_toefl',  
'jumlah_lomba']
```

3. Embedded Method

Metode embedded selector adalah metode seleksi fitur yang menggabungkan keunggulan metode filter dan metode wrapper. Metode ini menggunakan algoritma tertentu seperti Random Forest dan Lasso Regression

Random Forest Importance

```
from sklearn.ensemble import RandomForestRegressor  
  
model = RandomForestRegressor(n_estimators=10)  
  
model.fit(X,y)  
  
importances = model.feature_importances_  
  
result_df = pd.DataFrame({'Features':pd.DataFrame(X).columns,'Importances':importances})  
result_df.set_index('Importances')  
  
result_df = result_df.sort_values('Importances')  
result_df.plot.barh(color = 'blue')
```



```
result_df.sort_values(by=['Importances'], ascending=False)
```



```
{'model__alpha': np.float64(0.7000000000000001)}
```

```
coefficients = search.best_estimator_.named_steps['model'].coef_  
coefficients
```

```
array([-0.          , -4.05580718, -0.          , -0.          ,  0.01678553,  
       0.25302873,  0.          , -0.          , -0.          , -0.          ,  
      -0.27508091,  0.          ,  0.          ,  0.          ,  0.23012911,  
       0.          , -0.42340742, -4.26923645, -1.01658509, -0.          ,  
      -2.86312817,  5.23643765,  1.52061431, -0.          , -0.          ,  
       0.          ,  0.          ,  0.          ,  1.74209815,  0.54436142])
```

```
importance = np.abs(coefficients)  
importance
```

```
array([0.          ,  4.05580718,  0.          ,  0.          ,  0.01678553,  
       0.25302873,  0.          ,  0.          ,  0.          ,  0.          ,  
       0.27508091,  0.          ,  0.          ,  0.          ,  0.23012911,  
       0.          ,  0.42340742,  4.26923645,  1.01658509,  0.          ,  
       2.86312817,  5.23643765,  1.52061431,  0.          ,  0.          ,  
       0.          ,  0.          ,  0.          ,  1.74209815,  0.54436142])
```

```
features = X.columns
```

```
np.array(features)[importance > 0]
```

```
array(['umur', 'kos', 'uang_saku', 'status_menikah', 'ip_sem4', 'gamer',  
      'durasi_sosmed (jam/hari)', 'jumlah_akun_sosmed', 'jumlah_org',  
      'score_toefl', 'jumlah_lomba', 'ipk', 'lulus_tepatwaktu'],  
      dtype=object)
```

```
np.array(features)[importance == 0]
```

```
array(['jenis_kelamin', 'konsentrasi', 'asal', 'paket_data', 'kendaraan',  
      'laptop', 'tipe_laptop', 'ip_sem1', 'ip_sem2', 'ip_sem3',  
      'kacamata', 'clubbing', 'keadaan_ortu_divorced', 'romance',  
      'ukuran_sepatu', 'tinggi_badan', 'berat_badan'], dtype=object)
```

Kesimpulan

- Filter methods (seperti korelasi) cepat dan sederhana, cocok untuk tahap awal eksplorasi data atau dataset yang sangat besar. Namun, mereka tidak mempertimbangkan interaksi antar fitur.
- Wrapper methods (seperti Forward/Backward Selection) sering kali menghasilkan subset fitur yang baik untuk model tertentu karena mereka mengevaluasi kinerja model secara langsung. Namun, mereka bisa sangat lambat pada dataset dengan banyak fitur.
- Embedded methods (seperti Lasso atau Random Forest Importance) menawarkan keseimbangan antara kecepatan dan akurasi, serta dapat menangani interaksi fitur dan non-linearitas sampai batas tertentu.

Tugas

Lakukan feature selection dengan target 'lulus_tepatwaktu' menggunakan tiga metode : Filter, Wrapper, dan Embedding.

Pilih salah satu cara untuk masing-masing metode

Lakukan analisis hasilnya

Penamaan file : NIM_feature_selection.ipynb

Link pengumpulannya : <https://forms.gle/5PhVy1UXthJyhs8T6>

Referensi

- <https://www.naukri.com/learning/articles/feature-selection-techniques-python-code/>
- <https://www.datalearns247.com/feature-selection-menggunakan-scikit-learn-71>
- <https://towardsdatascience.com/feature-selection-with-pandas-e3690ad8504b>
- <https://towardsdatascience.com/feature-selection-in-machine-learning-using-lasso-regression-7809c7c2771a>
- <https://www.analyticsvidhya.com/blog/2020/10/a-comprehensive-guide-to-feature-selection-using-wrapper-methods-in-python/>

- <https://www.trivusi.web.id/2019/02/metode-metode-dalam-feature-selection.html>